

Diplomatura en Inteligencia Artificial

Clasificación de imágenes
con deep learning

Esp. Ing. Juan Ignacio García
Universidad Nacional de Cuyo




Clasificación en imágenes

2

La tarea de clasificación en imágenes se refiere a la **etiquetación** de los **elementos principales** presentes en una imagen, en función de la geometría observada.


Es una tarea **supervisada**, por lo que los datasets de ejemplo deben nombrar la categoría a la que pertenecen las imágenes de antemano.




Redes fully connected aplicadas a imágenes

3

La primer aproximación que se puede tomar para la tarea de clasificar imágenes puede ser utilizar una red fully connected para analizar **cada píxel** de la imagen.



Esto trae dos **inconvenientes**: el tamaño de la red y que no es invariante a escala, traslación o rotación.




Capa convolucional

5

Hasta el momento se ha visto que un filtro convolucional permite **detectar** una estructura dentro de la imagen.



La intuición dice que hay un modo de **automatizar el diseño** de esos filtros. Para ello, la herramienta seleccionada es una **red neuronal**.



Una capa convolucional permite diseñar N filtros en paralelo sobre una misma imagen.

Como resultado, se obtienen N imágenes en las que se resalta la información que captura cada filtro.

Coloquialmente se dice que aplicar estos filtros sobre la imagen “ensancha” la información que procesa la red.



Capa de pooling

7

El resultado de la capa convolucional deja **espacio vacío** que se puede considerar espacio inútil almacenado.


La operación de pooling **resume** la información de un área en un único valor, reduciendo el **tamaño** del grupo de imágenes.



Coloquialmente se dice que la operación de pooling “achata” el conjunto de imágenes que procesa.

La particularidad de esta capa es que solo **modifica las dimensiones** de las imágenes, no su información.

Estas capas **no son entrenables**, de modo que se ignoran en el proceso de entrenamiento.




Redes neuronales convolucionales (CNN)

9


Este tipo de redes son el estado del arte en la **clasificación** de imágenes.

Su estructura **combina capas** convolucionales y de pooling hasta reducir el tamaño del bloque de imágenes lo suficiente para procesarlas con una **red fully connected**.



El proceso de **backpropagation**, en las capas convolucionales se ajusta mediante la **regla de la cadena** considerando el error entre la etiqueta de entrenamiento y la predicha por el modelo.

Se puede demostrar que la actualización sobre las capas convolucionales consiste en una **correlación cruzada** entre la entrada de la capa y el mapa de error; y la actualización sobre la entrada es la **convolución** entre el mapa de error y el propio kernel rotado 180° .




Arquitecturas modernas

11

LeNet-5 es la **primer red** convolucional moderna **exitosa** y se utilizó para el **reconocimiento de números manuscritos**.

Sus capas convolucionales reducen la dimensionalidad y las capas profundas finales combinan las características.


Tiene **~60 000 parámetros**.



LeNet-5 funcionaba bien para imágenes de muy **baja resolución** y pocas clases en la salida.



VGG-16 se diseña con el concepto de que redes **más pequeñas y profundas** pueden realizar mejor trabajo que capas convolucionales de mayor tamaño en menor número.

Esta arquitectura emplea en total **~138 000 000 parámetros**.



Si bien VGG demuestra que hacer capas **más profundas mejora el desempeño** de la clasificación, existe un límite a partir del cual se comienza a degradar la información.

Se identificó el problema como una **reducción en la magnitud** de los gradientes a medida que se propagaban por mayor cantidad de capas (**vanishing gradient**).




La arquitectura ResNet introduce un cambio conceptual en la estructura de la red:

$$H(x) \rightarrow x \Rightarrow H(x) - x \rightarrow 0$$

Este cambio implica trabajar sobre **modificaciones** respecto al vector original en lugar de estimar dicho vector desde cero.

Esta arquitectura usa **~25 000 000** parámetros y es el **estado del arte** en clasificación de imágenes.




Data augmentation

15

Las redes convolucionales requieren un **gran volumen** de datos que resultan costosos y ambiguos de etiquetar.

La técnica de data augmentation consiste en generar **nuevas imágenes** aplicando variaciones sobre los registros ya almacenados.



Horizontal

Vertically



Flip o reflexión



Crop

Translate

Recorte



Jitter de color

+45 Rotation

-45 Rotation



Rotación

Horizontal Flip



Crop



Median Blur



Contrast



Hue / Saturation / Value



Gamma



Ajuste de contraste,
brillo y saturación




Blur

Transfer learning

17

El proceso de entrenamiento desde cero demora **semanas** en algunos casos.


La ventaja de las redes profundas es que **jerarquizan** las características que detectan según la **profundidad** de las capas.



Esto permite seccionar la red en dos: una parte que captura **generalidades** y otra que **observa** detalles.


Es posible **congelar** las capas generales y traspasar estas capas a otras aplicaciones.

Este proceso se llama **feature extraction** y aprovecha el entrenamiento hecho por grandes centros de cómputo.



En la etapa de **fine tuning** se actualizan solo las capas **más profundas** para detectar características particulares de la aplicación.

Esto permite **acelerar** el tiempo de entrenamiento y también se **disminuye** el tamaño del dataset necesario para entrenar la red.




Proceso de entrenamiento

20

El dataset en estas aplicaciones se suele dividir en tres:


- Entrenamiento: **actualizar** los parámetros de la red.
- Validación: tomar decisiones sobre **hiperparámetros**.
- Test: reportar **resultados**.




- Accuracy: casos **predichos correctamente** sobre el total
- Precisión y recuperación: qué fracción de los positivos son correctamente **predichas** o **detectadas**, respectivamente. Estas medidas se aplican a **cada clase**.



- Matriz de confusión: **contabilización** de la clasificación de cada imagen.
- Curva ROC: mide **umbrales de decisión**.



- Dropout: se desactiva **aleatoriamente** cada neurona para forzar a la red a **distribuir** el aprendizaje de patrones.
- Weight decay (L2 regularization): **penaliza** pesos w grandes y **reduce** sus valores, simplificando la red.
- Early stopping: se **detiene** el entrenamiento cuando la pérdida en validación comienza a **aumentar**.



¿Alguna pregunta?