

Diplomatura en Inteligencia Artificial

Detección de objetos en
imágenes

Esp. Ing. Juan Ignacio García
Universidad Nacional de Cuyo



Segmentación

2

La segmentación es una **capa** que agrupa todos los píxeles que **pertenecen** a un mismo grupo.

Se clasifica en segmentación **semántica** (cada clase se agrupa bajo una máscara distinta) o **por instancia** (cada objeto se agrupa bajo una máscara distinta).




Segmentador por ventana deslizante

3

El primer método concebido hace un **recorte en torno** al píxel que quiere clasificar.

El recorte se procesa por una **CNN** que infiere a qué clase pertenece y lo **asigna** a una capa.

Se repite el proceso **píxel a píxel** hasta procesar toda la imagen.



Autoencoders

4

Se trata de una técnica para **comprimir** el tamaño que ocupa una imagen conservando la mayor parte de la información.

Para ello se construye una CNN cuyo objetivo es **reducir** una imagen todo lo posible y luego **reconstruirla**.


El error de la red es la diferencia con la **imagen original**.



¿Osc tclryhy jc tcl y jy qcekclryagml
qmzpc jy bcrcaagml?

Una vez la red es creada se puede dividir en tres partes:

1. Encoder: Es la parte que **reduce la imagen**, haciendo representaciones abstractas.
2. Bottleneck: Es la parte **más estrecha** de la red. Contiene la información comprimida.
3. Decoder: Es la parte que **reinterpreta** la información del bottleneck.




Fully convolutional network


6

Se busca procesar toda la imagen **a la vez** con una misma CNN.


Para ello, **se corta** la parte que aplanan la red de modo que la clasificación se aplique **a cada píxel** resultante en lugar de a la imagen como a un todo.




Como en las capas más profundas un píxel **representa una región más grande** en la imagen original, se aplica la operación inversa del pooling, el **upsampling**, hasta recuperar las dimensiones originales.




Antes del upsampling
(21, 65, 65)



Después del upsampling
(21, 520, 520)




A la salida de la red se aplican tantas **capas de clasificación** como clases se quieran detectar, que describen la **probabilidad** de que un píxel pertenezca a cada clase.





La información que se recupera durante el upsampling tiende a **perder información**, particularmente sobre los contornos de los objetos.

Para mejorar la **fidelidad** del decoder, se implementa una técnica llamada **skip connections**.



Esta técnica consiste en **copiar** la información de cada convolución (previo a las etapas de pooling) y utilizarla para **compararla** con la capa resultante del upscaling.

La comparación se realiza con **kernels** que ponderan la información de ambas capas.



Nuevamente se diseñan maneras de comparar el **solapamiento** entre la máscara predicha y la real, pero **a nivel píxel**. Las métricas más comunes son:


- IoU Loss: Coincidencia entre máscaras.
- Dice Loss: Más peso a la intersección.

Para la segmentación de instancias resulta necesario primero entender las **fronteras** de cada objeto, aún si pertenecen a una misma clase.


Este mismo problema trataban de resolver las **estructuras R-CNN**.




Image Recognition



Semantic Segmentation




Object Detection



Instance Segmentation


Mask R-CNN es una arquitectura que se apoya en Faster R-CNN y FCN para **detectar distintos objetos** en su bounding box y usa esa región reducida para **segmentar** solo esta zona.

A diferencia de Faster R-CNN cuyas técnicas de pooling se **pierden muchos detalles** del contorno de los objetos, se implementa **RoI Align**, que hace más preciso este proceso.




En esta etapa del proceso ya se tiene información del **recorte** de la imagen en el que se quiere segmentar.

En **paralelo** a la localización y clasificación del bounding box de cada objeto, se introduce una capa FCN que permite evaluar la **pertenencia de cada píxel** de la región a cada categoría existente.



Los modelos a veces dan buenas respuestas pero aprendiendo **patrones equivocados**.

Estos errores se conocen como **correlaciones espurias**, donde dos variables aparentan estar vinculadas pero en realidad no es así.




La **explicabilidad** es una propiedad por la cual se destacan las partes de una imagen importantes para inferir un resultado.


Una forma fácil de saberlo es entender qué celdas al final de un modelo de segmentación son **más activas**.

Para poder medir esto se emplea el **gradiente** de cambio de una clase respecto al feature map que se quiere evaluar.

Tras ponderar y superponer los resultados más influyentes de la salida de la red, se realiza un **upscaling** para observar esta importancia sobre la imagen original. Este proceso debe repetirse para **cada clase**.



- DeepLab: Convoluciones dilatadas para segmentar objetos en **regiones más grandes**.
- SegFormer: Introduce **mecanismos de atención** para comprender detalles locales y su relación con el contexto global.
- SAM (Segment Anything Model): Convierte la segmentación en una tarea **guiada por prompts**.



¿Alguna pregunta?